

RnD-1: Поправки на множественные проверки в A/A-конбаланса и в итогах A/B, связь с мэтчингом

Статус: Draft Область: A/B эксперименты, pre-check (A/A), балансировка/мэтчинг

1. Контекст и постановка

В экспериментальной платформе есть два разных по смыслу блока проверок:

- 1) Итоговый анализ A/B по одной или нескольким целевым метрикам (endpoints), по которым принимается решение о внедрении.
- 2) Предэкспериментальный контроль разбиения (часто называемый A/A), где проверяется сопоставимость групп по набору ковариат (включая лаги таргета и вспомогательные признаки). Иногда это реализовано как множество тестов (t -test/KS/ χ^2) с порогом по p-value. При «плохом» результате выполняется регенерация разбиения (перандомизация).

Проблема: при росте числа ковариат вероятность «хотя бы одного значимого отличия» быстро растёт даже при корректной рандомизации. Это провоцирует лишние итерации и создаёт ложное ощущение «некачественного сплита».

2. Вопросы

- Q1. Нужна ли поправка на множественные проверки при подведении итогов A/B по нескольким целевым метрикам?
- Q2. Нужна ли поправка на множественные проверки при контроле баланса до пилота, если используется p-value-гейтинг по многим ковариатам?
- Q3. Как корректно формализовать accept/reject в перандомизации и не превратить процесс в «p-hacking на сплитах»?
- Q4. Как это связано с мэтчингом и ковариатной корректировкой?

3. Выводы

3.1 Итоги A/B по нескольким метрикам: поправка обычно нужна

Если правило успеха устроено как «успех, если значима хотя бы одна из m метрик», то без контроля множественности растёт вероятность ложноположительного «успеха» на уровне эксперимента. В таких случаях требуется заранее выбрать стратегию контроля ошибок:

- FWER: Bonferroni / Holm (когда цена ложного успеха высока),
- FDR: Benjamini-Hochberg (когда метрик много и анализ скорее exploratory),
- либо иерархия endpoints (primary $\rightarrow$ secondary).

Если заранее зафиксирована primary-метрика, по которой принимается решение, а вторичные метрики не используются для «катим/не катим», то жёсткая поправка для вторичных может быть не нужна (при дисциплине pre-registration дизайна).

3.2 Контроль баланса до пилота: p-values не являются хорошим критерием «гомогенности»

Baseline-p-values зависят от N и не измеряют величину дисбаланса. При большом числе ковариат ложные «срабатывания» ожидаемы даже при идеальном рандоме. Поэтому попытка «лечить» проблему поправкой на множественность в baseline-тестах (например, Bonferroni) — чаще инженерная регулировка жёсткости гейта, а не корректная статистическая постановка.

Рекомендуемый подход: баланс как диагностика (effect size), а accept/reject строить через один агрегированный критерий дисбаланса.

3.3 Перандомизация: корректное правило принятия решения

Перандомизация (rejection sampling of assignments) должна быть частью дизайна эксперимента:

- 1) До генерации разбиений фиксируем список ковариат и их приоритеты (tiers/weights).
- 2) Выбираем метрику дисбаланса (например, $\max|SMD|$ по ключевым ковариатам; опционально агрегированная дистанция).
- 3) Выбираем порог τ проспективно, предпочтительно через целевую долю принятых разбиений (acceptance rate p_a , например 1–10%).
- 4) Ограничиваем бюджет: $\max_iter / \text{time-limit}$.
- 5) Fail-safe: если $\max_iter$ исчерпан — смягчаем требования только по low-priority ковариатам или переходим к стратификации по 1–2 ключевым категориям.
- 6) Логируем: seed, число попыток, значения критерия.

4. Рекомендации для реализации в библиотеке

- 1) Итоги A/B: добавить опции Holm / Bonferroni / BH-FDR, поддержку иерархии endpoints (primary -> secondary).
- 2) Pre-check (A/A): заменить «гейт по множеству p-values» на:
 - отчёт по SMD/разностям долей (диагностика),
 - агрегированный критерий принятия (например $\max|SMD|$ по top-covariates).
- 3) Перандомизация: формализовать API: criterion, threshold/acceptance_rate, max_iter, tiers/weights, seed, обязательное логирование.

5. План экспериментов на синтетике (для notebook.ipynb)

- Рост вероятности «хотя бы одного ложного флага» при росте числа ковариат K при нулевом эффекте.
- Сравнение частоты ложных флагов: без коррекции vs Bonferroni vs Holm vs BH.
- Сравнение числа итераций перандомизации и качества баланса:
- p-value-гейт (как baseline),
- $\max|SMD|$ -гейт (как рекомендуемый вариант).

6. Литература

- FDA. *Multiple Endpoints in Clinical Trials: Guidance for Industry* (Oct 2022).
<https://www.fda.gov/regulatory-information/search-fda-guidance-documents/multiple-endpoints-clinical-trials>
- de Boer et al. (2015). *Testing for baseline differences in randomized controlled trials: an unhealthy research behavior that is hard to eradicate.*
<https://pmc.ncbi.nlm.nih.gov/articles/PMC4310023/>
- Senn S. (1994). *Testing for baseline balance in clinical trials.* Stat Med. DOI: 10.1002/sim.4780131703.
<https://pubmed.ncbi.nlm.nih.gov/7997705/>
- Benjamini Y., Hochberg Y. (1995). *Controlling the False Discovery Rate...* DOI: 10.1111/j.2517-6161.1995.tb02031.x
<https://doi.org/10.1111/j.2517-6161.1995.tb02031.x>