

RnD-6: Safe in-time covariates для CUPAC-style снижения дисперсии

Статус: в работе. Реализованы синтетический бенчмарк и цепочка методов
A/B → CUPAC A → A+B → A+B+C; подключены адаптеры реальных open-source датасетов и проведён расширенный скаутинг с delta-эффектами на A-only (раздел «Expanded public dataset validation»). Источник правды по B/C-числам — `notebook.ipynb` (синтетика, `seed=11`).

Цель

Проверить, даёт ли последовательное добавление безопасных in-time признаков поверх scikit-CUPAC дополнительное снижение дисперсии (и сокращение требуемой выборки) без нарушения методологической корректности оценки ATE.

Классы признаков (safety layer)

- A pre-treatment — идут в CUPAC;
- B expert-safe in-time — линейная second-stage коррекция;
- C balance-gated in-time — линейная коррекция после balance/missingness gate;
- D dag-required — вне estimator (нужна causal-проверка);
- E mediator-risk, F leakage — запрещены для основной оценки ATE;
- unsafe_demo — только демонстрация риска, не кандидат.

Методы

`ab_hypex` (A/B baseline) · `hypex_cupac` (reference/parity, вне цепочки) · `sklearn_cupac_A` → `sklearn_cupac_A_plus_B_linear` → `sklearn_cupac_A_plus_B_plus_C_linear` (основная цепочка прироста) · `unsafe_demo_optional` (демонстрация).

Результаты на синтетике (n=8000, seed=11, истинный ATE = 2.8)

method	ate	p_value	variance_reduction_vs_ab_%	incremental_vs_predecessor_%	safety_status
ab_hypex	2.758	0.0	0.0	—	ok
hypex_cupac	2.785	0.0	13.56	—	reference_only
sklearn_cupac_A	2.801	0.0	25.63	25.63	ok
sklearn_cupac_A_plus_B_linear	2.775	0.0	42.38	22.52	ok
sklearn_cupac_A_plus_B_plus_C_linear	2.766	0.0	52.80	18.07	ok
unsafe_demo_optional	1.000	0.0	83.17	—	unsafe_demo

(Снижение требуемой выборки в первом приближении совпадает со снижением дисперсии.)

Ключевые выводы

- Каждая безопасная группа даёт дополнительный выигрыш: A (~26%) → +B (~42%) → +B+C (~53%) снижения дисперсии относительно A/B, при этом ATE остаётся несмещённым (≈ 2.8).
- CUPAC parity: `hypex_cupac` (~14%) сопоставим по логике с `sklearn_cupac_A`; локальная реализация удобнее для R&D и используется как основная.
- Balance/missingness gate пропускает A/B/C ($|SMD| \approx 0$) и отклоняет D/E/F и `unsafe_demo` ($|SMD| \approx 0.45\text{--}1.14$, $p \approx 0$) — наглядно, почему их нельзя брать в estimator.
- `unsafe_demo` даёт максимальное «снижение дисперсии» (~83%), но смещает оценку ATE далеко от истинного 2.8 — примерно к 1.0 (см. таблицу) — демонстрация ловушки outcome-derived

признаков; в кандидатные методы не входит.

Безопасность и ограничения

- balance-test — практический gate (после исключения очевидных E/F), а не доказательство причинной безопасности; для D-признаков нужен будущий DAG/causal-этап.
- E/F запрещены; safe-intime используется только в линейном second-stage, не в произвольной ML-модели.

Статус валидации на реальных данных

- Синтетика подтверждает полную цепочку A+B+C (таблица выше): только там классы A/B/C/D/E/F известны по построению.
- Публичные реальные датасеты сейчас поддерживают в основном A-only CUPAC-валидацию. Сырой аудит (download + schema_summary) покрыл Orange Belgium, Lenta, Criteo, X5 RetailHero, MegaFon, Lazada/DESCN, CUVET-policy, MT-LIFT, Dunnhumby и semi-synthetic causal-бенчмарки.
- Hillstrom проверяет pipeline/A-only, не B/C.
- Реальные safe in-time B/C отсутствуют: признаки либо анонимны (f^* , PC^* , X_*), либо это пре-кампейн агрегаты (A), либо пост-treatment поведение (E/F). Датасеты с настоящими таймстемпами либо скрывают дату кампании (X5), либо не рандомизированы (Dunnhumby).
- Полная A+B+C-валидация на публичных реальных датасетах не подтверждена и остаётся неподтверждённой, пока сырой аудит не найдёт защитимых B/C-колонок с timing-evidence.
- Детали и пятичастная классификация датасетов: docs/06_real_dataset_raw_audit.md.

Expanded public dataset validation

Расширенный скаутинг (поиск шире классических uplift-наборов + реальная загрузка/инспекция + прототипы адаптеров + фактические delta-эффект прогоны). Полный отчёт и таблица представительности: docs/06_expanded_dataset_scouting.md.

Представительность классов признаков (по факту схем, не по документации):

- A (pre-treatment) — 9+ реальных кандидатов имеют A-признаки по схеме (+ синтетика), но фактический delta-эффект прогнан и подтверждён на 5 из них (hillstrom, orange_belgium, lazada_descn, lenta, x5 — таблица ниже). Остальные A/sandbox-кандидаты остаются на уровне схемы/документации (criteo — access_blocked; open_bandit/dunnhumby/criteo_private_ad — sandbox, не прогнаны как реальная A-валидация).
- B (expert-safe in-time) — 0: ни один публичный набор не выкладывает именованные, семантически интерпретируемые in-time экспертно-безопасные колонки.
- C-кандидаты (реальные, защитимые) — 0; sandbox-конструкция C теоретически возможна на 2 event-log датасетах (Open Bandit, dunnhumby), но это не реальная валидация.
- D-кандидаты — 5 (Criteo exposure; Lazada biased-train propensity; Open Bandit action/position/pscore; CriteoPrivateAd display/privacy-механика; dunnhumby campaign/coupon).
- E/F/unsafe-кандидаты — 7+ (Hillstrom visit/conversion; Criteo exposure; X5 пост-коммуникационные покупки; Open Bandit reward-производные; CriteoPrivateAd delayed click/sale; dunnhumby redemption и др.).

Только-A валидация (real RCT/uplift): Hillstrom, Lenta, X5 RetailHero, Orange Belgium, Lazada/DESCN (рандомизированный test), Criteo (слабый A-only). C/D-«песочницы» (не A/B): Open Bandit (logged bandit), dunnhumby Complete Journey (observational), CriteoPrivateAd (advertising logs) — полезны для *исследования* C/D-механики, не валидируют causal-корректность safe in-time.

Полная A+B+C-валидация на публичных реальных датасетах не подтверждена. Однако C/D-представительность можно исследовать на event-log / bandit / advertising / journey


datasets, которые не являются прямыми A/B uplift benchmark.


Сводная таблица итогов (delta-эффекты + песочницы)

A-only цепочка ab_hypex → sklearn_cupac_A, seed=11. Прогон: python tools/audit_datasets.py --delta; артефакты — results/06_safe_intime_cupac/ (expanded_dataset_delta_results.csv, sandbox_diagnostics.csv, figures/).

dataset	тип	validation_level	n	A-призн.	ATE (A/B)	var.red CUPAC-A vs A/B, %	safety
hillstrom	real RCT	A_only_real	64 000	18	0.597	0.06	ok
orange_belgium	real RCT	A_only_real	11 896	336	-0.0028	6.06	ok
lazada_descn	real uplift	A_only_real	181 669	83	0.0037	5.41	ok
lenta	real uplift	A_only_real	687 029	196	0.0075	14.36	ok
x5_retailhero	real uplift	A_only_real	200 039	10	0.0332	16.10	ok
dunnhumby	research_sandbox	C_D_sandbox	2 469	49	118.2 → -0.15 *	57.9	sandbox
criteo_private_ad	event_log_sandbox	D_F_sandbox	10 000	18	-0.0173	19.2	sandbox

* dunnhumby — observational: CUPAC-A здесь не «безопасно снижает дисперсию», а меняет оценку (ATE 118.2 → -0.15), потому что A-признаки сильно несбалансированы (это конфаундеры, не просто шум). Не валидация, а демонстрация: без рандомизации даже A нельзя считать safe.






Итоги по реальным (рандомизированным) данным:

- CUPAC-A даёт реальное снижение дисперсии 0-16%; сильнее всего там, где есть содержательные pre-treatment признаки — lenta (~14%, именованные пре-кампейн агрегаты) и X5 (~16%, engineered история покупок). ATE стабилен (несмещён).
- hillstrom — A-only smoke: spend крайне шумный, A-вклад ~0.06%.
- Цепочки +B/+B+C на реальных данных не запускались (реальных B/C-колонок нет) → delta-эффекты B/C подтверждены только на синтетике (таблица выше).
- Доступ/исключения: criteo (Uplift) — HTTP 403 (access_blocked); open_bandit — пакет obp несовместим с pandas 2.x (DataFrame.drop("col", 1)), runtime-blocked. Оба — в representativeness, но не в прогоне.

Sandbox-диагностика (balance gate + демонстрация рисков)

Для песочниц прогнан diagnose() — balance gate по классам признаков (results/06_safe_intime_cupac/sandbox_diagnostics.csv). Это не safe-валидация, а полигон, показывающий *почему* observational/ad-данные и D/F-признаки опасны.



- dunnhumby (observational journey): balance gate проходит лишь 6% A-признаков ($|SMD|_{\max} \approx 1.4$); C/D/E — 0%. Без рандомизации даже «pre-treatment» признаки сильно несбалансированы (конфаундинг). Демо C-sandbox (A+C): ATE $-0.15 \rightarrow 0.77$, var.red 57.9% $\rightarrow$ 59.2% — ATE неинтерпретируем как causal.
- criteo_private_ad (ad-логи): демо-treatment display_order==1; gate_pass: A — 56%, D — 58%, F — 100% (по построению ~независимы от демо-трита). F-leakage демо (A+F): var.red 19.2% $\rightarrow$ 93.5% при сдвиге ATE $-0.0173 \rightarrow -0.0008$ — классическая ловушка утечки: outcome-derived признаки рисуют «эффективность», ломая оценку. Поэтому E/F запрещены в estimator.

Рекомендация по переносу в NurEx

Подход показывает устойчивый прирост на синтетике и сопоставим с NurEx CUPAC; на реальных публичных данных подтверждён A-only вклад CUPAC-A (0–16% снижения дисперсии, 5 датасетов). Пере-переносом в NurEx необходимо:

1. Подтвердить вклад В/С на внутренних корпоративных данных, а не на публичных. Расширенный скаутинг показал, что публичные датасеты не валидируют В/С (реальных именованных safe in-time колонок с timing-evidence нет; см. «Expanded public dataset validation»). Поэтому В/С-валидацию следует переносить на внутренние данные (VarWar-класса), где timing и семантика признаков известны и защищены.

2. Формализовать balance/missingness gate как переиспользуемый компонент.

3. Зафиксировать запрет E/F и отдельный статус unsafe_demo.

Предыдущее свидетельство эффективности CUPAC на реальных данных — VarWar (снижение дисперсии ~34% и ~33%; данные приватны, не коммитятся) — это и есть пример внутреннего источника, на котором можно проверять В/С.

Воспроизведение

```

pip install -e .[ml]
# см. notebook.ipynb; график ATE±CI и таблица собираются из rnd_reports.benchmark
# delta-эффекты + sandbox-диагностика (читают gitignored data/, raw не коммитятся):
python tools/audit_datasets.py --delta # → results/06_safe_intime_cupac/{*.csv, figures/}
python tools/generate_pdf.py           # пересобрать report.pdf (фигуры встраиваются)

```