

R&D-8. Сравнение методов множественного тестирования (в OR-регионе)

Статус: базовый эксперимент готов. Логика — в пакете `src/rnd_reports/multiple_testing/` (на готовых решениях `scipy/statsmodels`; своё — только Romano-Wolf stepdown), витрина — `notebook.ipynb`. Числа и фигуры — синтетика, `seed=42/1`.

Цель

В A/B-пилоте с несколькими метриками вопрос начинается не с «какую поправку применить», а с типа утверждения (claim). Цепочка: метрики → роли → семейства гипотез → логика claim → метод. Этот RnD ограничен OR-регионом: есть заранее заданное семейство target-метрик, и нас интересует «есть ли в нём хотя бы один надёжный сигнал и какие именно метрики его дали». Ложный успех такого OR-claim — хотя бы одно ложное отвержение, поэтому контролируем FWER. Задача RnD — честно сравнить методы OR-региона между собой.

Данные и контракт

Таблица формата `id, treatment, target_1, ..., target_n`: `treatment` — бинарный индикатор (0=control, 1=treatment), каждая числовая `target_*` — отдельная гипотеза о treatment effect (разница средних). Контракт одинаков для синтетики и реальной таблицы; синтетика (`make_ab_table`) дополнительно отдаёт известные `true_effects`, что позволяет мерить power и FWER. Коррелированность метрик (параметр `rho`) — ключевой фактор различия методов.

Методы

Метод	Контроль ошибки	Опора	Идея
Bonferroni	FWER	statsmodels	порог α/m , union bound; прост, консервативен
Holm	FWER	statsmodels	stepdown по отсортированным p-value; не слабее Bonferroni
Westfall-Young (maxT)	FWER	scipy + перестановки	калибровка по распределению максимума абсолютных t семейства; учитывает корреляцию
Romano-Wolf (stepdown)	FWER	перестановки (своя реализация)	максимум абсолютных t по сужающемуся активному множеству; мощнее WY
Benjamini-Hochberg	FDR	scipy	единственный FDR-ориентир (exploratory-компаратор)

Bonferroni/Holm используют только вектор raw p-value и игнорируют корреляцию метрик. Westfall-Young и Romano-Wolf используют совместное распределение тестовых статистик (перестановки treatment-лейблов) и потому выигрывают в мощности на коррелированных метриках при том же контроле FWER. BH контролирует FDR — мощнее, но допускает больше ложных находок; это компаратор для exploration, а не launch-процедура OR-claim.

Дизайн сравнения


- Single-table (`run_comparison`) — adjusted p-value и решения всех методов на одной

таблице. Работает и на своей реальной таблице (в ноутбуке — одна помеченная ячейка подмены); при известной правде добавляет TP/FP/realized-FDR/power.


- Operating characteristics (operating_characteristics) — Monte-Carlo: усреднение по многим симуляциям с известной правдой. По сетке корреляций ρ считаем эмпирический FWER (доля симуляций с ≥ 1 ложным отвержением) и average power. Только так методы сравнимы честно — одна реализация таблицы для этого недостаточна.

Результаты

Single-table. На сильных сигналах все методы согласованы; различие — на грани значимости, где Romano-Wolf / Westfall-Young менее консервативны, чем Bonferroni/Holm, при том же контроле FWER.




Детальнее по каждой метрике — эффект с доверительным интервалом (слева) и raw/adjusted p-value по методам в лог-шкале с порогом α (справа): видно, как FWER-коррекция отодвигает p-value к незначимости и какие метрики дают надёжный сигнал. Цвет точек слева — по самому ДИ: красные не включают 0 (сырой сигнал, до поправки на множественность), синие включают; решения методов с поправкой полностью отражены на правой панели, поэтому левая не привязана к одному методу.




Сравнение «через p-values». Помимо reject-решений методы сравниваются скалярными сводками из adjusted p-value (res.pvalue_profile): средний adjusted-p на истинно-ненулевых метриках (mean_p_adj_signal — сила детекции), на нулевых (mean_p_adj_null — калибровка) и зазор консервативности conservativeness_gap = среднее p_adj — p_raw (инфляция над raw; единственная из трёх величин, считается и на реальной таблице, где правда неизвестна). Это законная общая шкала для FWER-методов: их adjusted p-value отвечают на один вопрос («минимальный α , при котором метод отвергает гипотезу») и контролируют одну ошибку, поэтому видно упорядочение по консервативности (Bonferroni $\geq$ Holm $\geq$ Westfall-Young $\geq$ Romano-Wolf). Benjamini-Hochberg в той же таблице помечен error_control = FDR: его adjusted p-value — это q-value другой валюты ошибки (ожидаемая доля ложных среди отвергнутых, а не вероятность хоть одной ложной), поэтому его строку читаем отдельно и не усредняем с FWER-методами.

Operating characteristics. Главное различие видно на зависимости мощности от корреляции метрик: power Westfall-Young / Romano-Wolf растёт с ρ (≈ 0.49 при $\rho=0 \rightarrow \approx 0.66$ при $\rho=0.9$), тогда как Bonferroni/Holm остаются плоскими ($\approx 0.48 \rightarrow \approx 0.43$) — они корреляцию не используют.



При этом FWER всех четырёх FWER-методов держится у $\alpha=0.05$, а Benjamini-Hochberg (FDR) даёт более высокий уровень ложных находок — ожидаемая плата за большую мощность.



Выводы

- Для коррелированного OR-семейства — Romano-Wolf / Westfall-Young (заметный выигрыш в мощности без потери контроля FWER).
- Для малого простого семейства — Holm/Bonferroni (почти та же мощность, проще объяснить и воспроизвести).
- Benjamini-Hochberg — для exploration (поиск кандидатов), не для launch-решения OR-claim.

Вне scope этой версии

Из таблицы id, treatment, target_* без дополнительной конфигурации нельзя честно вывести другие регионы пространства множественного тестирования (см. конспект-методологию): co-primary / intersection-union (нужны обязательные условия успеха), no-harm / non-inferiority (guardrail-метрики, направление вреда, margin), gatekeeping / fixed sequence (порядок claims/families), graphical procedures (узлы, alpha-веса, routing), closed testing (комбинаторный взрыв пересечений). Они требуют ролей метрик и decision-logic, задаваемых вне таблицы. Бизнес-декомпозиция вклада (effect sizes, CI, OEC) — отдельная задача, которую p-value не закрывают.